Algoritmo Genético para Seleção de Passagens SAR: Comparação de Métodos de Seleção, Taxas e Elitismo

Matheus V. M. Sales e William M. S. S. Silva
Instituto Nacional de Pesquisas Espaciais (INPE)
São José dos Campos, SP, Brasil
{matheus.sales, william.silva}@inpe.br

***Resumo*—Constelações de satélites de radar de abertura sintética (SAR) oferecem muitas oportunidades de aquisição sobre uma mesma região, e escolher quais passagens adquirir é um problema combinatório: é preciso cobrir as áreas de interesse com poucas aquisições e pouca sobreposição entre faixas. Este trabalho aplica um algoritmo genético (AG) com codificação binária à seleção de 702 passagens da constelação ICEYE sobre sete áreas de interesse na Amazônia, que somam cerca de 210 mil km^2. A aptidão combina, em uma soma ponderada, a fração da área coberta, a fração de passagens selecionadas e a sobreposição entre faixas. São comparados os métodos de seleção por roleta, torneio e ranking linear, diferentes taxas de cruzamento e mutação e a execução com e sem elitismo, pelas curvas de convergência e pela aptidão final. O torneio, de maior pressão de seleção, obteve a maior aptidão entre os métodos de seleção; a taxa de mutação mais alta (0,15) impediu a evolução; e o elitismo garantiu o crescimento sem oscilações da melhor aptidão, enquanto as demais variações de taxa ficaram dentro da variação entre execuções. Nenhuma configuração convergiu em 40 gerações, o que indica a necessidade de mais gerações e de várias execuções por cenário.**

***Palavras-chave*—algoritmo genético, cobertura de área, elitismo, métodos de seleção, otimização combinatória, radar de abertura sintética**

I. Introdução

O monitoramento da Amazônia por sensores ópticos é limitado pela cobertura frequente de nuvens [1], o que favorece os sensores de radar de abertura sintética (SAR), capazes de imagear através delas [2]. Com as constelações de pequenos satélites SAR, as oportunidades de aquisição sobre uma mesma região se multiplicam, mas as faixas imageadas se sobrepõem e cada aquisição tem custo. O problema é, então, escolher um subconjunto de passagens que cubra as áreas de interesse com poucas aquisições e pouca sobreposição. Com N passagens candidatas, há 2^N subconjuntos possíveis; trata-se de uma variante do problema de cobertura de conjuntos, que é NP-difícil [3], o que motiva o uso de meta-heurísticas como o algoritmo genético (AG) [4].

Neste trabalho, consideram-se sete áreas de interesse na Amazônia, que somam cerca de 210 mil km^2, e $N = 702$ passagens candidatas da constelação ICEYE, em banda X e modo *Stripmap*, previstas entre 14 de junho e 15 de agosto de 2023 (Fig. 1). As faixas são muito redundantes: se todas fossem adquiridas, cada ponto das áreas seria imageado, em média, 12,8 vezes.

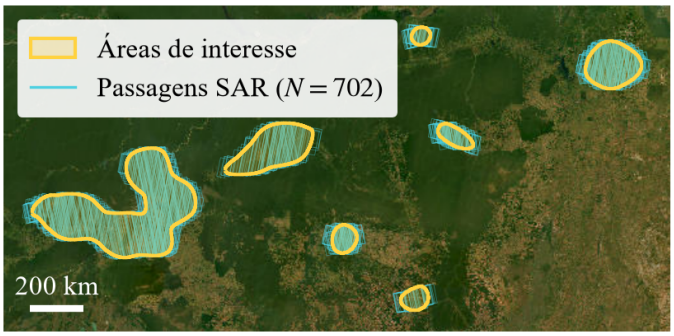


Fig. 1. Áreas de interesse e contornos das 702 passagens SAR candidatas. Imagem de fundo: Esri World Imagery.

O objetivo é aplicar um AG a esse problema e comparar, pelas curvas de convergência e pela aptidão final, (a) os métodos de seleção por roleta, torneio e ranking, (b) diferentes taxas de cruzamento e mutação e (c) a execução com e sem elitismo. O desempenho do AG depende diretamente dessas escolhas [5].

II. Algoritmo Genético

Cada indivíduo é um vetor $\mathbf{x} \in \{0,1\}^N$, com um gene por passagem, e sua aptidão é o valor da função objetivo f, definida na Seção III [6], [7]. A população inicial, de tamanho M, é sorteada com probabilidade 0,5 por gene. A cada geração, a população é substituída integralmente por filhos gerados por seleção, cruzamento e mutação; com elitismo, o melhor indivíduo é mantido sem alterações.

A seleção define a *pressão de seleção*, isto é, o quanto os indivíduos mais aptos são favorecidos: pressão alta acelera a convergência, mas reduz a diversidade e aumenta o risco de convergência prematura [8], [9]. Na roleta, a probabilidade de seleção é proporcional à aptidão, transladada pelo mínimo da população porque f pode ser negativa:

$$p_i = \frac{f_i - f_{\min}}{\sum_{j=1}^{M}(f_j - f_{\min})}. \tag{1}$$

No ranking linear [10], ela depende apenas da posição r_i do indivíduo na ordenação crescente de aptidão:

$$p_i = \frac{2\,r_i}{M(M+1)}. \tag{2}$$

TABELA I
PRESSÃO DE SELEÇÃO DOS TRÊS MÉTODOS

Método	Depende de	Cópias esperadas do melhor
Roleta	valores de f	$\frac{f_{\max} - f_{\min}}{\bar{f} - f_{\min}}$
Ranking linear	ordem	$\frac{2M}{M+1} \approx 2$
Torneio ($k = 3$)	ordem	3

No torneio, sorteiam-se $k = 3$ indivíduos e vence o mais apto. Como mostra a Tabela I, ranking e torneio dependem só da ordem dos indivíduos e têm pressão constante, maior no torneio, enquanto na roleta a pressão varia com a distribuição das aptidões na população. Espera-se, portanto, que o torneio convirja mais rápido que o ranking e que o desempenho da roleta dependa do estado da população.

O cruzamento é de um ponto, com corte fixo na metade do cromossomo, e é aplicado a cada par de pais com probabilidade p_c; caso contrário, os filhos são cópias dos pais. Em seguida, cada gene é invertido com probabilidade p_m, o que altera em média $p_m N$ genes por indivíduo. Assim, p_c regula quanto da nova geração vem de recombinação, e p_m, quanta perturbação é introduzida: com p_m alto, a herança dos pais se perde e a busca se aproxima de uma amostragem aleatória. Um valor de referência usual é $p_m \approx 1/N$ [11].

Como a substituição é geracional, o melhor indivíduo pode ser destruído por cruzamento ou mutação. O elitismo [12] evita essa perda copiando-o para a geração seguinte, de modo que a melhor aptidão da população nunca diminui; sem ele, o AG canônico não converge em probabilidade para o ótimo global [13].

III. METODOLOGIA

A. Função objetivo

Cada passagem i é representada pelo polígono P_i de sua faixa imageada no solo, e A denota a união das áreas de interesse. Para uma solução $\mathbf{x} \in \{0,1\}^N$, em que $x_i = 1$ indica que a passagem i foi selecionada, sejam

$$U(\mathbf{x}) = \Big| \bigcup_{i:\, x_i = 1} (P_i \cap A) \Big|, \tag{3}$$

$$S(\mathbf{x}) = \sum_{i=1}^{N} x_i \, |P_i \cap A|, \tag{4}$$

em que $|\cdot|$ denota área: U é a área efetivamente coberta, e S soma a área coberta por cada passagem, contando as repetições. A aptidão combina três critérios normalizados em [0,1]:

$$\mathrm{AC}(\mathbf{x}) = \frac{U(\mathbf{x})}{|A|}, \tag{5}$$

$$\mathrm{NP}(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^{N} x_i, \tag{6}$$

$$\mathrm{SO}(\mathbf{x}) = \frac{S(\mathbf{x}) - U(\mathbf{x})}{S(\mathbf{x}) + U(\mathbf{x})}, \tag{7}$$

que são, respectivamente, a fração da área de interesse coberta, a fração das passagens selecionadas e a sobreposição entre faixas, nula quando nenhum ponto é imageado mais de uma vez. A função objetivo, a ser maximizada, é

$$f(\mathbf{x}) = w_1 \, \mathrm{AC}(\mathbf{x}) - w_2 \, \mathrm{NP}(\mathbf{x}) - w_3 \, \mathrm{SO}(\mathbf{x}), \tag{8}$$

com os pesos definidos em aula, $w_1 = 1{,}0$, $w_2 = 1{,}5$ e $w_3 = 0{,}5$. Os critérios são conflitantes: acrescentar passagens aumenta AC, mas também NP e, em geral, SO.

TABELA II
CONFIGURAÇÃO DOS EXPERIMENTOS

Parâmetro	Valor
Configuração base	
Tamanho da população (M)	50
Gerações	40
Execuções por cenário	1
Seleção	torneio ($k = 3$)
Taxa de cruzamento (p_c)	0,8
Taxa de mutação (p_m)	0,01
Elitismo	sim (1 indivíduo)
Testes comparativos	
(a) Seleção	roleta, torneio, ranking
(b) p_c, com $p_m = 0{,}01$	0,6; 0,8; 0,9
(b) p_m, com $p_c = 0{,}8$	0,005; 0,01; 0,15
(c) Elitismo	com, sem

B. Parâmetros e testes comparativos

A Tabela II resume a configuração. Cada teste parte da configuração base e varia um único fator: (a) o método de seleção; (b) a taxa de cruzamento ou a de mutação; e (c) a presença de elitismo. Com $N = 702$, as taxas de mutação testadas alteram em média 3,5, 7 e 105 genes por indivíduo, contra a referência de um gene ($p_m = 1/N$). Cada cenário foi executado uma vez, com 40 gerações de 50 indivíduos (2.000 avaliações), em Python com GeoPandas e Shapely, no Google Colab. As áreas são obtidas por interseção e união de polígonos, operações que dominam o custo computacional.

Em cada geração, registram-se a melhor aptidão da população e a aptidão média dos M indivíduos, que formam as curvas de convergência, além de AC, NP e SO da melhor solução encontrada.

IV. RESULTADOS

As Figs. 2 a 4 mostram as curvas de convergência, e a Tabela III, a aptidão no início e no fim de cada execução. Como cada cenário foi executado uma única vez, parte das diferenças decorre da população inicial: a configuração base,

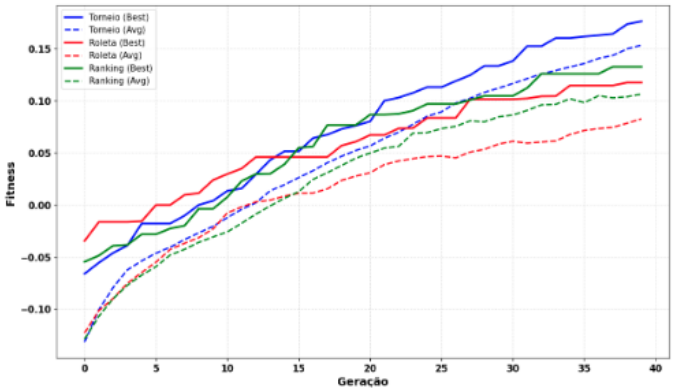


Fig. 2. Convergência por método de seleção, com uma execução por método: melhor aptidão (Best, linhas cheias) e aptidão média da população (Avg, tracejadas). O torneio é a configuração base.

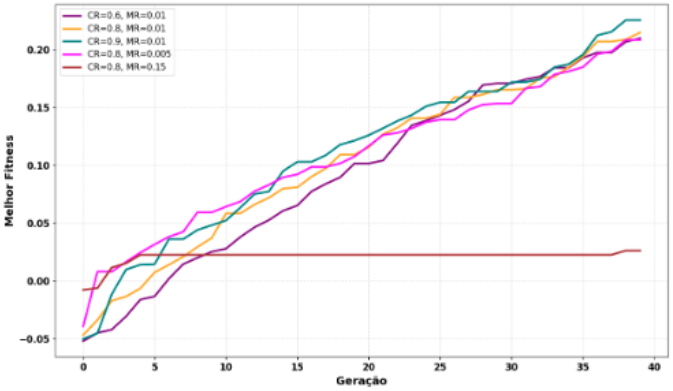


Fig. 3. Melhor aptidão por geração para as taxas de cruzamento (CR, p_c) e de mutação (MR, p_m), com uma execução por cenário. A configuração base é $p_c = 0{,}8$ e $p_m = 0{,}01$.

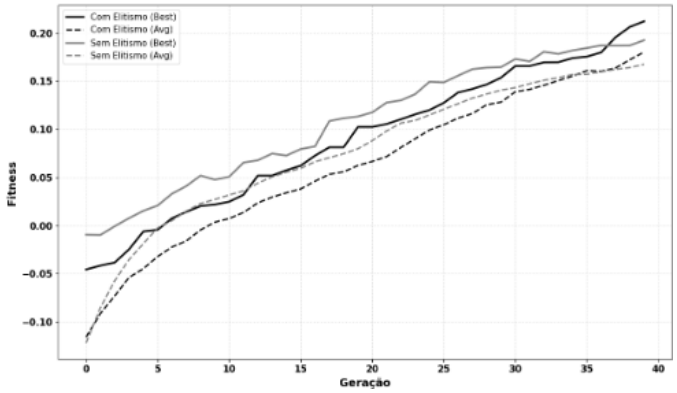


Fig. 4. Convergência com e sem elitismo: melhor aptidão (Best, linhas cheias) e aptidão média da população (Avg, tracejadas).

presente nos três testes, terminou com melhor aptidão entre 0,177 e 0,215. Diferenças menores que cerca de 0,04 não podem, portanto, ser atribuídas com segurança à técnica.

Na seleção (Fig. 2), o torneio partiu da pior população inicial e terminou com a maior aptidão, tanto do melhor indivíduo (0,177, contra 0,133 do ranking e 0,118 da roleta) quanto da média da população (0,150, contra 0,104 e 0,083). Essa ordem coincide com a da pressão de seleção (Tabela I). A roleta começou à frente, mas estagnou: nas últimas cinco gerações, seu melhor indivíduo melhorou 0,0006 por geração, contra 0,0033 no torneio.

TABELA III
APTIDÃO DO MELHOR INDIVÍDUO E MÉDIA DA POPULAÇÃO

Cenário	Melhor ger. 0	Melhor ger. 39	Média ger. 39
(a) Seleção			
Roleta	$-0{,}034$	0,118	0,083
Torneio†	$-0{,}065$	0,177	0,150
Ranking linear	$-0{,}054$	0,133	0,104
(b) Taxas			
$p_c = 0{,}6$	$-0{,}052$	0,210	–
$p_c = 0{,}8$, $p_m = 0{,}01$†	$-0{,}046$	0,215	–
$p_c = 0{,}9$	$-0{,}050$	0,226	–
$p_m = 0{,}005$	$-0{,}037$	0,209	–
$p_m = 0{,}15$	$-0{,}007$	0,026	–
(c) Elitismo			
Com elitismo†	$-0{,}046$	0,212	0,180
Sem elitismo	$-0{,}010$	0,192	0,167

†Configuração base. Valores de (a) e (b) lidos das curvas (precisão de $\pm 0{,}002$).

Nas taxas (Fig. 3), p_c = 0,6, 0,8 e 0,9 terminaram em 0,210, 0,215 e 0,226, e p_m = 0,005, em 0,209: diferenças dentro da variação entre execuções, sem efeito conclusivo. Já p_m = 0,15, que altera em média 105 genes por indivíduo, impediu a evolução: o melhor indivíduo ficou parado em 0,022 da 4.ª à 37.ª geração, sustentado apenas pelo elitismo, enquanto a aptidão média da população ficou em torno de $-0{,}05$.

Com elitismo (Fig. 4), a melhor aptidão cresceu sem oscilações; sem elitismo, ela caiu sete vezes, ainda que pouco (no máximo 0,004). Mesmo partindo de uma população inicial pior ($-0{,}046$ contra $-0{,}010$), a execução com elitismo ultrapassou a outra na geração 37 e terminou à frente (0,212 contra 0,192).

Em todos os cenários, exceto p_m = 0,15, as curvas ainda subiam na última geração, ou seja, 40 gerações não bastaram para a convergência. A melhor solução da execução com elitismo ($f = 0{,}212$) cobre 99,6% da área de interesse com 228 passagens (32% das candidatas), mas ainda com $\mathrm{SO} = 0{,}59$, o que indica redundância a eliminar.

Em síntese, entre os métodos de seleção, o torneio, de maior pressão de seleção, obteve a melhor aptidão; a taxa de mutação alta impediu a evolução; e o elitismo garantiu o crescimento sem oscilações da melhor aptidão. As variações de p_c e as taxas de mutação baixas tiveram efeito menor que a variação entre execuções. Trabalhos futuros devem usar mais gerações e várias execuções por cenário, para confirmar estatisticamente essas diferenças.

REFERÊNCIAS

[1] G. P. Asner, "Cloud cover in Landsat observations of the Brazilian Amazon," *International Journal of Remote Sensing*, vol. 22, no. 18, pp. 3855–3862, 2001.

[2] A. Moreira, P. Prats-Iraola, M. Younis, G. Krieger, I. Hajnsek, and K. P. Papathanassiou, "A tutorial on synthetic aperture radar," *IEEE Geoscience and Remote Sensing Magazine*, vol. 1, no. 1, pp. 6–43, 2013.

[3] R. M. Karp, "Reducibility among combinatorial problems," in *Complexity of Computer Computations*, R. E. Miller and J. W. Thatcher, Eds. New York: Plenum Press, 1972, pp. 85–103.
[4] J. E. Beasley and P. C. Chu, "A genetic algorithm for the set covering problem," *European Journal of Operational Research*, vol. 94, no. 2, pp. 392–404, 1996.
[5] A. E. Eiben, R. Hinterding, and Z. Michalewicz, "Parameter control in evolutionary algorithms," *IEEE Transactions on Evolutionary Computation*, vol. 3, no. 2, pp. 124–141, 1999.
[6] J. H. Holland, *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI: University of Michigan Press, 1975.
[7] D. E. Goldberg, *Genetic Algorithms in Search, Optimization, and Machine Learning*. Reading, MA: Addison-Wesley, 1989.
[8] D. E. Goldberg and K. Deb, "A comparative analysis of selection schemes used in genetic algorithms," in *Foundations of Genetic Algorithms*, G. J. E. Rawlins, Ed. San Mateo, CA: Morgan Kaufmann, 1991, pp. 69–93.
[9] T. Blickle and L. Thiele, "A comparison of selection schemes used in evolutionary algorithms," *Evolutionary Computation*, vol. 4, no. 4, pp. 361–394, 1996.
[10] J. E. Baker, "Adaptive selection methods for genetic algorithms," in *Proc. 1st Int. Conf. Genetic Algorithms and Their Applications*, J. J. Grefenstette, Ed. Hillsdale, NJ: Lawrence Erlbaum, 1985, pp. 101–111.
[11] A. E. Eiben and J. E. Smith, *Introduction to Evolutionary Computing*, 2nd ed. Berlin: Springer, 2015.
[12] K. A. De Jong, "An analysis of the behavior of a class of genetic adaptive systems," Ph.D. dissertation, University of Michigan, Ann Arbor, MI, 1975.
[13] G. Rudolph, "Convergence analysis of canonical genetic algorithms," *IEEE Transactions on Neural Networks*, vol. 5, no. 1, pp. 96–101, 1994.